



UNIVERSIDADE ESTADUAL DO NORTE DO PARANÁ  
CAMPUS LUIZ MENEGHEL - CENTRO DE CIÊNCIAS TECNOLÓGICAS  
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

KAIO FELIPE BARBOSA GARCIA

**RECONHECIMENTO FACIAL DE ANIMAIS: UM ESTUDO  
PRÁTICO**

BANDEIRANTES-PR

2023

**KAIO FELIPE BARBOSA GARCIA**

**RECONHECIMENTO FACIAL DE ANIMAIS: UM ESTUDO  
PRÁTICO**

Trabalho de Conclusão de Curso apresentado  
ao curso de Bacharelado em Ciência da Com-  
putação da Universidade Estadual do Norte  
do Paraná para obtenção do título de Bacha-  
rel em Ciência da Computação.

Orientador: Prof. Me. José Reinaldo Merlin

**BANDEIRANTES-PR**

**2023**

KAIO FELIPE BARBOSA GARCIA

## **RECONHECIMENTO FACIAL DE ANIMAIS: UM ESTUDO PRÁTICO**

Trabalho de Conclusão de Curso apresentado ao curso de Bacharelado em Ciência da Computação da Universidade Estadual do Norte do Paraná para obtenção do título de Bacharel em Ciência da Computação.

### **BANCA EXAMINADORA**

---

Prof. Me. José Reinaldo Merlin  
Universidade Estadual do Norte do Paraná  
Orientador

---

Prof(a). Dr(a). Daniela de Freitas  
Guilhermino Trindade  
Universidade Estadual do Norte do Paraná

---

Prof. Dr. Ederson Marcos Sgarbi  
Universidade Estadual do Norte do Paraná

Bandeirantes–PR, 10 de fevereiro de 2023

*Este trabalho é todo dedicado aos meus pais, pois é graças aos seus esforços que hoje posso concluir o meu curso.*

## **AGRADECIMENTOS**

Quero agradecer a todos os amigos, familiares, professores, em especial ao meu orientador de TCC, prof. José Reinaldo Merlin, pela oportunidade e apoio na elaboração deste trabalho. Também aos meus pais, pelo amor, incentivo e apoio incondicional.

“A coisa mais bela que podemos viver é o mistério. É a fonte de toda arte e ciência verdadeira.” - Lemony Snicket

GARCIA, K. F. B.. **Reconhecimento Facial de Animais: um estudo prático.** 29 p. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Universidade Estadual do Norte do Paraná, Bandeirantes–PR, 2023.

## RESUMO

Reconhecimento facial é uma tecnologia muito utilizada pelo mundo. É uma técnica em que algoritmos utilizam análise profunda de imagem para identificar um indivíduo. Essa tecnologia é usada em fazendas para substituir métodos antigos e invasivos de identificação. O objetivo deste trabalho é estudar a tecnologia de reconhecimento facial de animais e aplicar um algoritmo para estudar seu processo de aplicação e seus resultados. Para treinar o algoritmo escolhido foi preciso ir a campo a fim de capturar dados dos animais de uma fazenda e realizar testes. Após o treinamento, o algoritmo foi capaz de identificar os animais através de imagens. Porém algumas variáveis encontradas durante a captura dos dados afetaram os resultados obtidos.

**Palavras-chave:** Reconhecimento Facial; Animais; Aprendizagem de máquina; Visão computacional.

GARCIA, K. F. B.. **Animal Facial Recognition: a practical study.** 29 p. Final Project (Bachelor of Science in Computer Science) – State University Northern of Parana , Bandeirantes–PR, 2023.

## ABSTRACT

Facial recognition is a widely used technology around the world. It is a technique in which algorithms use deep image analysis to identify an individual. This technology is used on farms to replace old and invasive methods of identification. The goal of this paper is to study animal facial recognition technology and apply an algorithm to study its application process and results. To train the chosen algorithm it was necessary to go into the field to capture animal data from a farm and perform tests. After training, the algorithm was able to identify the animals through images. However, some variables encountered during the data capture affected the results obtained.

**Keywords:** Facial Recognition; Animals; Machine Learning; Computer Vision.

## **LISTA DE ILUSTRAÇÕES**

Figura 1 – Padrões encontrados em um focinho bovino . . . . .	16
Figura 2 – Fotos dos Animais . . . . .	18
Figura 3 – Pastas do Dataset . . . . .	19
Figura 4 – Curva de Precisão e Perda . . . . .	21
Figura 5 – Teste 1 - Tufão . . . . .	22
Figura 6 – Teste 4 - Princesa . . . . .	22
Figura 7 – Teste 2 - Inocência . . . . .	23
Figura 8 – Teste 1 - Chifrinho10 . . . . .	23
Figura 9 – Teste 2 - Chifrinho10 . . . . .	23
Figura 10 – Jove, Tufão, Novilha03 e Branquinha . . . . .	24
Figura 11 – Teste 1 - Jove . . . . .	24
Figura 12 – Teste 2 - Novilha03 . . . . .	24

## **LISTA DE ABREVIATURAS E SIGLAS**

CNN	Convolutional Neural Network - Rede Neural Convolucional
CSS	Cascading Style Sheets - Folhas de Estilo em Cascata
HTML	Hypertext Markup Language - Linguagem de Marcação de Hipertexto
RFID	Radio Frequency Identification - Identificação por Radiofrequência

# SUMÁRIO

<b>1</b>	<b>INTRODUÇÃO . . . . .</b>	<b>11</b>
<b>1.1</b>	<b>Delimitação e Formulação do Problema . . . . .</b>	<b>11</b>
<b>1.2</b>	<b>Objetivos . . . . .</b>	<b>11</b>
<b>1.3</b>	<b>Metodologia . . . . .</b>	<b>11</b>
<b>1.4</b>	<b>Justificativa . . . . .</b>	<b>12</b>
<b>2</b>	<b>FUNDAMENTAÇÃO TEÓRICA . . . . .</b>	<b>13</b>
<b>2.1</b>	<b>Reconhecimento Facial . . . . .</b>	<b>13</b>
<b>2.2</b>	<b>Reconhecimento de Animais . . . . .</b>	<b>14</b>
<b>2.3</b>	<b>Métodos de Reconhecimento . . . . .</b>	<b>14</b>
<b>2.4</b>	<b>Obstáculos e Dificuldades no Reconhecimento . . . . .</b>	<b>14</b>
<b>2.5</b>	<b>Tecnologias . . . . .</b>	<b>15</b>
<b>2.6</b>	<b>Estratégias . . . . .</b>	<b>15</b>
<b>2.7</b>	<b>Algoritmos . . . . .</b>	<b>15</b>
<b>3</b>	<b>DESENVOLVIMENTO . . . . .</b>	<b>17</b>
<b>3.1</b>	<b>Materiais e Métodos . . . . .</b>	<b>17</b>
<b>3.1.1</b>	<b>Aquisição das Imagens . . . . .</b>	<b>17</b>
<b>3.1.2</b>	<b>Algoritmo e Treinamento . . . . .</b>	<b>20</b>
<b>3.2</b>	<b>Resultados e Discussão . . . . .</b>	<b>21</b>
<b>3.2.1</b>	<b>Testes das Imagens . . . . .</b>	<b>21</b>
<b>4</b>	<b>CONCLUSÃO . . . . .</b>	<b>25</b>
	<b>REFERÊNCIAS . . . . .</b>	<b>26</b>
	<b>APÊNDICES</b>	<b>28</b>
	<b>APÊNDICE A – CÓDIGO . . . . .</b>	<b>29</b>

# **1 INTRODUÇÃO**

Reconhecimento facial é uma tecnologia utilizada em grande escala pelo mundo. Trata-se de uma técnica em que algoritmos de visão computacional utilizam análise profunda de imagem para identificar um indivíduo. Essa técnica é utilizada pela polícia para monitoramento, os celulares modernos utilizam como senha e possui diversas outras aplicações, incluindo seu uso em animais. Atualmente essa tecnologia é usada apenas nas grandes fazendas de gado, devido a diversos fatores ela não chegou às pequenas fazendas.

O uso dessa tecnologia inovadora nas fazendas surgiu da necessidade de substituir métodos antigos e invasivos de identificação e controle dos animais, como marcação corporal e brincos identificadores. O reconhecimento facial por se tratar de um método não invasivo e automatizado possibilita o registro automático de informações dos animais. Assim gerando dados preciosos para os criadores.

## **1.1 Delimitação e Formulação do Problema**

Neste trabalho será feito um estudo prático sobre reconhecimento facial de animais, aplicando um algoritmo e analisando a sua aplicação, resultados e as variáveis encontradas que podem alterar o resultado encontrado.

O estudo dessa tecnologia pode facilitar seu uso. Pois trata-se de um processo complexo que engloba várias etapas. Um estudo que documenta seu processo de aplicação ajuda a disseminar o conhecimento dessa tecnologia que ainda não é utilizada em larga escala.

## **1.2 Objetivos**

O objetivo do trabalho é utilizar um algoritmo de reconhecimento facial de animais encontrado em pesquisa, com o propósito principal de estudar sua aplicação e funcionamento. Indo desde a aplicação em campo até seus resultados encontrados. Também estudar essa tecnologia emergente, seu contexto, vantagens, desvantagens, dificuldades e formas de uso.

## **1.3 Metodologia**

Os passos que foram seguidos no trabalho são:

- **Revisão Bibliográfica:** foram pesquisados e documentados os algoritmos e estudos que auxiliaram no entendimento da tecnologia para as etapas seguintes;

- **Estudo da Tecnologia:** foi realizado um estudo sobre a tecnologia de reconhecimento facial em animais e seu contexto, vantagens, desvantagens, dificuldades e formas ideais de uso;
- **Análise dos Algoritmos:** com os algoritmos e trabalhos documentado foi possível passar para a análise dos mesmos e das tecnologias (como as CNN e as bibliotecas);
- **Seleção e Aplicação do Algoritmo:** após o entendimento do algoritmo e de como usá-lo, foi possível selecionar um e aplicá-lo para tentar obter alguns resultados;
- **Análise dos Resultados:** os resultados dos testes foram analisados, junto com as variáveis que causaram variações nos resultados.

#### 1.4 Justificativa

O método do reconhecimento de animais surgiu como uma alternativa não invasiva para os métodos comuns, como brincos ou ferro quente, porém seus algoritmos são complexos e de difícil entendimento. Por isso devemos estudá-los e documentar seu uso para que essa tecnologia, que traz tantos benefícios, possa ser utilizada em maior escala.

## 2 FUNDAMENTAÇÃO TEÓRICA

Nesta seção é apresentada uma revisão de literatura sobre os temas relativos ao trabalho. Será apresentado o que é reconhecimento facial e suas fases, mostrando a relação do reconhecimento facial com os animais, algumas características dos algoritmos desse reconhecimento e mostrando alguns outros métodos de reconhecimento e identificação dos animais.

### 2.1 Reconhecimento Facial

Segundo Orvalho[1] a tecnologia conhecida por Reconhecimento Facial é capaz de identificar uma pessoa a partir de uma imagem digital ou de um vídeo e essa tecnologia já está presente em diversos campos da sociedade, como o das Ciências Forenses. Haralick[2] afirma que os algoritmos de visão computacional, como o de reconhecimento facial, são compostos de diferentes sub algoritmos, muitas vezes aplicados em sequência.

Schmidt[3] apresenta a tecnologia de reconhecimento facial como sendo composta por três etapas, seguidas sequencialmente, elas são: detecção da face, extração de características e reconhecimento da face.

A detecção é a fase em que a imagem é analisada e o algoritmo de detecção encontra o rosto e os pontos de referência nas imagens, que podem ser coisas como os olhos, o nariz, o queixo e as orelhas[3]. Nesta fase pode ser utilizado o processo de *data augmentation*, ou aumento de dados, que é um processo capaz de aumentar artificialmente a quantidade de dados a partir dos dados existentes. Uma de suas estratégias é a adição de pequenas alterações dos originais para amplificar o conjunto de dados[4].

A extração de características é a etapa em que um algoritmo realiza a análise da imagem que já teve um rosto encontrado e extrai as características dele as armazenando para a próxima fase. Se for um treino ela será guardada e se for para um teste será comparada a aquelas que foram armazenadas durante os treinamentos. Segundo Damasceno[5]:

A etapa de extração de características desempenha um papel importante no processo de reconhecimento, pois seleciona as melhores características discriminantes menos sensíveis a variação na pose, expressões faciais e variações de iluminação, reunindo-as em um vetor de características para a sua representação.

A etapa final é chamada de reconhecimento da face. É a fase em que o vetor das características, encontrado na fase anterior, é comparado com o conjunto dos vetores de

treino que também foram gerados pela fase de extração de características em busca de características semelhantes.

## 2.2 Reconhecimento de Animais

O uso da tecnologia de reconhecimento em animais, de acordo com Billah[6], é um passo importante para auxiliar no manejo animal e para a obtenção de dados significativos precisos para gerenciar a reprodução do gado em fazendas. Hansen[7] conta que essa tecnologia foi proposta como um método não invasivo para suprir a necessidade da identificação e controle individual dos animais.

Indo além das fazendas, seu uso na natureza traz uma revolução na maneira de coletar dados dos animais selvagens. Segundo Clapham et al.[8] as novas tecnologias de reconhecimento de animais apoiam uma nova era de pesquisas sobre a vida selvagem, gerando dados sobre escalas de indivíduos e suas populações. Os autores ainda afirmam que não existem métodos visuais objetivos de identificação individual para espécies que carecem de marcações corporais únicas e consistentes o que os motivou a aplicar técnicas de reconhecimento facial e *deep learning* para identificar e classificar ursos pardos (*Ursus arctos*), sua aplicação *open-source* foi chamada de *BearID*.

## 2.3 Métodos de Reconhecimento

O reconhecimento surgiu como uma alternativa às técnicas tradicionais de identificação e reconhecimento. Hansen[7] conta que o método de identificação de gado mais utilizado são as *tags* RFID de identificação por radiofrequência, que apesar de terem baixo custo sua colocação consome tempo e é angustiante para os animais, pois essas *tags* são colocadas em forma de brinco na orelha do animal.

As técnicas como tatuagem, marcação dos ouvidos ou implante de microchips são técnicas invasivas de identificação populares que deixam uma marca permanente no corpo do animal, porém esses métodos trazem muitos desafios, como infecções animais, septicemia leve e hemorragia[9].

## 2.4 Obstáculos e Dificuldades no Reconhecimento

Xue[10] apresenta que a postura e a posição do rosto das ovelhas, que foram o foco do reconhecimento, foram as variáveis que afetam o resultado final. Segundo Kumar[11], além do posicionamento do animal na imagem, a iluminação e o fundo também afetam o resultado, principalmente variando com as imagens tiradas *indoor* ou *outdoor*. A face dos animais nem sempre estão limpas, porcos por exemplo tendem a se sujar. Wang[12] conta que em alguns chiqueiros em que o algoritmo foi aplicado, as faces dos animais não eram limpas por um longo período de tempo e isso tornou difícil obter um bom resultado do

reconhecimento.

O principal desafio encontrado por Clapham[8] foi que o Deep Learning requer uma grandes conjuntos de dados rotulados para treino e testes. Estes dados são difíceis de se adquirir quando se trata de populações selvagens como os ursos pardos estudados, especialmente a nível individual. Matkowski[13] mostra as dificuldades encontradas no reconhecimento de espécies como os panda, em que seus *datasets* são poucos e pequenos, por causa do número de indivíduos e a pouca qualidade das imagens.

## 2.5 Tecnologias

Diversas tecnologias são utilizadas para construção dos algoritmos de reconhecimento facial. As Redes Neurais Convolucionais (Convolutional Neural Network-CNN), aplicadas nas etapas do reconhecimento, foi usada em [7] e foi treinada usando um conjunto de dados capturados utilizando uma *webcam* posicionada no bebedouro dos animais. Segundo [14], a CNN se trata de uma rede neural artificial do tipo *feedforward*, que costuma ser aplicada no processamento, análise e classificação de imagens digitais.

A linguagem de programação Python é utilizada em [15], juntamente com a biblioteca OpenCV, uma biblioteca *open source* multiplataforma de visão computacional e aprendizado de máquina, escrita em C/C++, que foi utilizado para treinar o algoritmo de classificação, pois a biblioteca fornece dois programas para formar um classificador em cascata Haar, *opencv-createsamples* e *opencv-traincascade*.

## 2.6 Estratégias

O reconhecimento da face não é a única estratégia na construção dos algoritmos. Bello[9] apresenta um sistema de reconhecimento individual de vacas da raça *Holstein-Frísia*, conhecida popularmente como Gado Holandês, que realiza o reconhecimento por meio dos padrões das manchas corporais. Já em Bello[16] o sistema de reconhecimento e identificação através da aprendizagem do padrão de imagem do nariz, semelhante às impressões digitais, como mostrado na Figura 1.

## 2.7 Algoritmos

BearID[8] é um algoritmo *open-source* que utiliza *deep learning* e imagens faciais para detectar e identificar ursos pardos (*Ursus arctus*), uma espécie que, de acordo com os autores, é um candidato ideal para expandir o reconhecimento facial para além dos primatas.

O Cattle Recognition [17] se trata de um algoritmo de identificação de gado bovino com Redes Neurais Convolucionais, sendo um software livre para utilização e modificação

Figura 1 – Padrões encontrados em um focinho bovino



**Fonte:** Bello, 2020[16]

como diz o autor na descrição do repositório. Esse algoritmo foi escolhido para ser aplicado e estudado nas próximas etapas deste trabalho por ser voltado para os bovinos.

## 3 DESENVOLVIMENTO

Este capítulo trata de como foi escolhido um algoritmo de reconhecimento facial, como foi feita a aquisição e tratamento dos dados, os resultados da aplicação e as conclusões.

### 3.1 Materiais e Métodos

Para o estudo da aplicação da tecnologia de reconhecimento facial em animais foi preciso selecionar um algoritmo de código aberto, sendo ele o Cattle Recognition [17]. A escolha foi feita com base nos seguintes critérios:

1. Ser código aberto, para ser possível alterá-lo e disponibilizá-lo após as alterações;
2. Ser voltado para gado bovino, animais que estavam à disposição para capturar imagens;
3. Ser um trabalho recente, para manter o estudo voltado para a tecnologia atual;
4. Estar disponível para consulta e comparação de sua versão original e a alterada; e
5. Utilizar tecnologias conhecidas e estudadas.

As modificações feitas no código do algoritmo foram a atualização das importações de bibliotecas e a remoção de funções extras que não seriam utilizadas, como os *templates* de páginas HTML e arquivos CSS, que não eram o foco deste trabalho. A versão modificada do algoritmo está disponível em um repositório público no GitHub, chamado Reconhecimento Facial Bovino<sup>1</sup>.

A tecnologia de reconhecimento facial é aplicada em etapas, iniciando com a aquisição das imagens dos animais para treinar o algoritmo, tratamento dos dados coletados, aplicação do algoritmo com as imagens adquiridas, análise dos resultados de treinamento, captura de imagens para testes, realização de testes e por análise dos resultados dos testes. Essas etapas devem ser seguidas de forma linear, com uma única exceção a aquisição das imagens de teste, que pode ser realizada junto com as anteriores.

#### 3.1.1 Aquisição das Imagens

Capturar as imagens dos animais é a etapa que deve-se ter maior atenção e cuidado pois há algumas escolhas de como será realizada a captura que evitam resultados negativos no decorrer da sequência de trabalho. Por exemplo, ao manter um fundo (*background*)

---

<sup>1</sup> <https://github.com/kaiofbgarcia/Reconhecimento-Facial-Bovino>

padronizado, em que há poucas variações de elementos evitando que o treinamento seja comprometido. Assim possibilita que o algoritmo identifique as características marcantes apenas dos animais e não do fundo.

A escolha dos animais que serão utilizados é de grande importância. No início do trabalho seriam usados os animais da fazenda da Universidade Estadual do Norte do Paraná - Campus Luiz Meneghel para a aplicação da tecnologia, porém, devido ao recesso da universidade de fim de ano, foi preciso substituí-los pelos animais de uma pequena fazenda localizada na cidade de Fartura-SP. Os proprietários Evandro Domingos Garcia e José Francisco Garcia deram autorização e auxílio para a realização das gravações. O ideal para realização do experimento de aplicação era que os animais não possuíssem brincos com número de identificação, porém não foram encontrados animais que cumprissem esse requisito.

Foram selecionados nove animais mostrados na Figura 2, sete deles foram escolhidos desejando algumas características marcantes diferentes entre eles como variação de idade, tamanho, sexo, coloração de pelo, chifres. Outros dois animais foram escolhidos por serem parecidos com um dos sete anteriores para testar se causaria confusão no algoritmo, o que será discutido na apresentação dos resultados. No Quadro 1 há uma lista dos animais e de suas características físicas, notáveis ao observá-los. Os nomes sublinhados são referentes aos dois animais escolhidos por serem parecidos uns com os outros.

Figura 2 – Fotos dos Animais



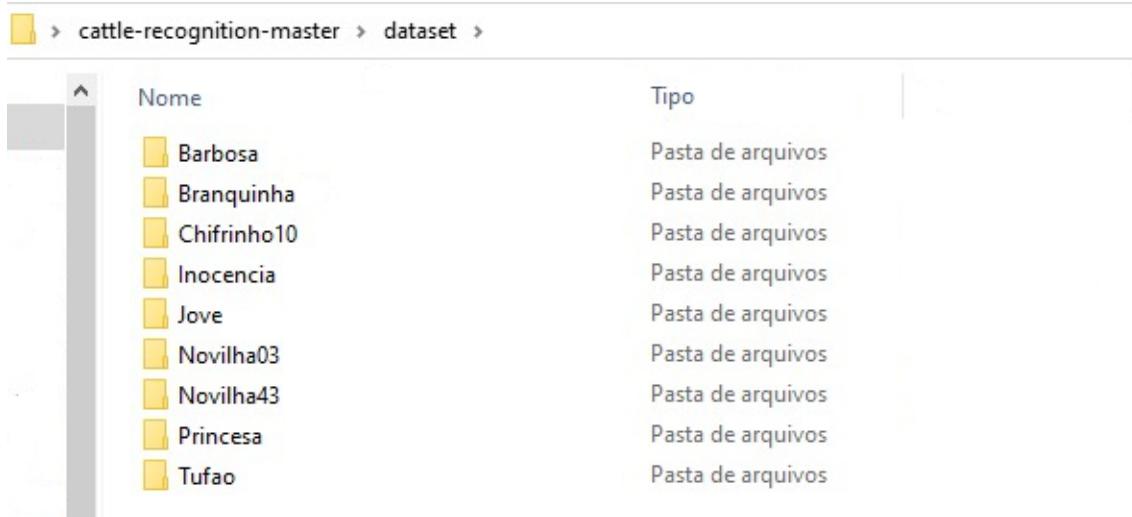
Antes do início da captura foi feita a escolha de utilizar vídeos que seriam transformados em imagens para facilitar a aquisição de grandes quantidades de dados, para fazer isso foi criado um programa simples em Python chamado *frames.py* que separa um vídeo

Quadro 1 – Animais Selecionados

Nome	Sexo	Idade	Porte	Pelo	Chifre	Outros
<b>Branquinha</b>	Femêa	Adulta	Médio/grande	Branco	-	-
<b>Barbosa</b>	Femêa	Adulta	Médio/grande	Branco com parte da cabeça amarronzada	Médio/grande voltados para cima	-
<b>Chifrinho10</b>	Femêa	Adulta	Médio/grande	Preto com mancha branca no centro dos chifres	Pequenos voltados para baixo	-
<b>Jove</b>	Macho	Filhote	Pequeno	Manchado de preto e branco	-	-
<b>Inocência</b>	Femêa	Filhote	Pequeno	Branco com parte da cabeça amarronzada	-	Orelhas grandes
<b>Novilha03</b>	Femêa	Filhote	Pequeno	Branco	-	Orelhas grandes
<b>Novilha43</b>	Femêa	Adulta	Médio/grande	Preto	Médio/grande voltados para cima	-
<b>Princesa</b>	Femêa	Adulta	Médio/grande	Branco com boa parte da cabeça amarronzada	-	-
<b>Tufão</b>	Macho	Adulto	Grande	Manchado de preto e branco	Pequenas pontas	Cupim localizado atrás do pescoço

em imagens, *frame* por *frame*. Para realizar as gravações foi utilizado um smartphone, modelo Xiaomi Redmi Note 9, cuja câmera utilizada grava em 30 fps (*frames* por segundo) e possui 48 MP (megapixels). As imagens obtidas devem ser armazenadas em pastas com o nome do animal, conforme mostrado na Figura 3, para que durante o treinamento o algoritmo defina esses nomes para as classes que representam cada um dos animais. Quatro dos animais não tinham nomes, então receberam um apelido com base em seu número de brinco. As pastas nomeadas devem ser colocadas dentro de uma pasta chamada “dataset” para que o algoritmo as encontre.

Figura 3 – Pastas do Dataset



Na Tabela 1 estão presentes as quantidades de imagens de teste e treino obtidas de cada animal e a quantidade total. A primeiro momento a ideia era capturar as imagens de cada animal de forma individual enquanto ele estivesse se alimentando em um cocho sozinho, porém essa forma se mostrou bastante difícil, pois não podemos controlar totalmente o comportamento do animal, o que dificultou a realização das gravações também,

alguns animais mais calmos foram mais fáceis de obter uma maior quantidade de imagens utilizáveis. Os filhotes foram os indivíduos que apresentaram maior dificuldade de se gravar porque sempre estavam juntos de outros animais ou muito agitados. A Inocência foi uma exceção, pois era recém nascida e estava separada dos demais.

Tabela 1 – Quantidade de Imagens no Dataset

<b>Nome</b>	<b>Treino</b>	<b>Teste</b>	<b>TOTAL</b>
<b>Branquinha</b>	2506	2	2508
<b>Barbosa</b>	2106	3	2109
<b>Chifrinho10</b>	3277	3	3280
<b>Jove</b>	354	2	356
<b>Inocência</b>	1469	3	1472
<b>Novilha03</b>	475	2	477
<b>Novilha43</b>	2863	2	2865
<b>Princesa</b>	1708	4	1710
<b>Tufão</b>	2480	2	2482
<b>TOTAL</b>	<b>17238</b>	<b>18</b>	<b>17256</b>

As imagens de teste tiveram que passar por um tratamento manual. Utilizando uma ferramenta de corte foi possível ajustar a imagem para focar apenas no animal, removendo partes indesejadas. Para esse experimento a quantidade de dados obtida foi suficiente, porém, para uma aplicação real seria necessário uma maior quantidade de imagens para se treinar o algoritmo.

### 3.1.2 Algoritmo e Treinamento

O algoritmo criado por Blanco foi escrito na linguagem Python e recomenda-se utilizar o Python 3.9, ou inferior, para o correto funcionamento de suas bibliotecas. Esse algoritmo suporta três modelos de rede neural: VGG16, ResNet50 e SeNet50. O que será utilizado é o ResNet-50, um modelo de rede neural convolucional de 50 camadas. O repositório conta com um README descritivo com os comandos necessários para execução e uma sequência de passos.

Com as imagens devidamente organizadas em pastas dentro de uma pasta *dataset* pode-se realizar a limpeza dos dados, uma etapa opcional e que não apresentou um funcionamento correto com grandes quantidades de imagens. O primeiro passo é utilizar o comando, mostrado abaixo, para executar o arquivo “*training.py*” que irá começar o treinamento.

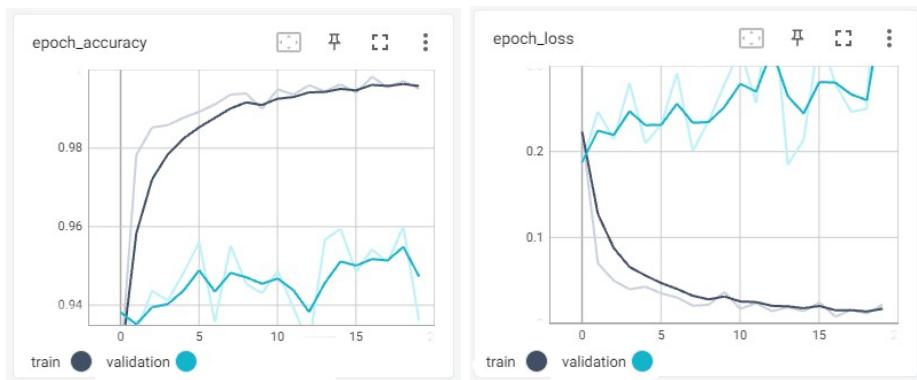
“*python training.py - -granja test - -model resnet50 - -epochs 20 - -batch\_size 30*”

No comando vemos que “test” refere-se ao nome escolhido para o treinamento (opcional), “resnet50” refere-se modelo de rede neural escolhido (resnet50, vgg16 e senet50),

“20” refere-se número de ciclos de treinamento que serão realizados (valor recomendado) e “30” refere-se ao número de exemplos de formação utilizados numa iteração (valor recomendado).

A execução final realizada foi nomeada de *TCCTestF*, o modelo e os valores se mantiveram como recomendado, seu treinamento durou aproximadamente doze horas e após cada um dos vinte ciclos exibia um valor de *Accuracy* e *Loss* do treino e da validação, que representam a exatidão e perda de um modelo de classificação, respectivamente, esses dados são mostrados em forma de gráficos (Figura 4), feitos automaticamente com a ferramenta TensorBoard.

Figura 4 – Curva de Precisão e Perda



## 3.2 Resultados e Discussão

Os primeiros resultados obtidos foram durante a fase de treino, como mostrado nos gráficos da Figura 4. No primeiro gráfico vemos que o modelo treinado apresentou uma boa acurácia no treinamento mas na validação apresentou forte *overfitting*. Segundo Montes[18], *overfitting* significa que um modelo se ajusta muito bem ao conjunto de dados mas apresenta dificuldade na previsão de novos resultados. Já no segundo é possível observar que se obteve uma boa taxa de aprendizagem no treinamento apesar da alta taxa de perda durante a validação, proporcional a acurácia.

### 3.2.1 Testes das Imagens

Para realizar testes individuais com as imagens deve-se utilizar um comando para executar o arquivo “*testing.py*”. Nele há a necessidade de informar qual o nome do treinamento que será testado e qual o caminho para imagem de teste, representados, respectivamente, pela parte em negrito no comando abaixo.

```
“python testing.py - -granja test - -img “path/to/img””
```

Os resultados dos testes individuais estão apresentados no Quadro 2. Durante esses testes foram obtidos resultados positivos, negativos, esperados e inesperados. Nas Figuras 5 e 6 vê-se dois testes de sucesso, ambos foram reconhecidas pelo algoritmo. Todos os testes mostrados nas figuras presentam à esquerda a imagem de teste que foi utilizada. Na Figura 7 pode-se notar que o Teste 2 da Inocência não correu como esperado, pois esse animal não possuía uma grande quantidade de dados de treinamento, o que pode ter causado essa confusão no resultado.

Quadro 2 – Resultados dos Testes Individuais

Nome	Teste 1	Teste 2	Teste 3	Teste 4
<b>Branquinha</b>	✓	✓	-	-
<b>Barbosa</b>	X	✓	X	-
<b>Chifrinho10</b>	X	X	✓	-
<b>Jove</b>	X	✓	-	-
<b>Inocência</b>	✓	X	✓	-
<b>Novilha03</b>	✓	✓ / X	-	-
<b>Novilha43</b>	✓	✓	-	-
<b>Princesa</b>	✓	✓	✓	✓
<b>Tufão</b>	✓	✓	-	-

Figura 5 – Teste 1 - Tufão

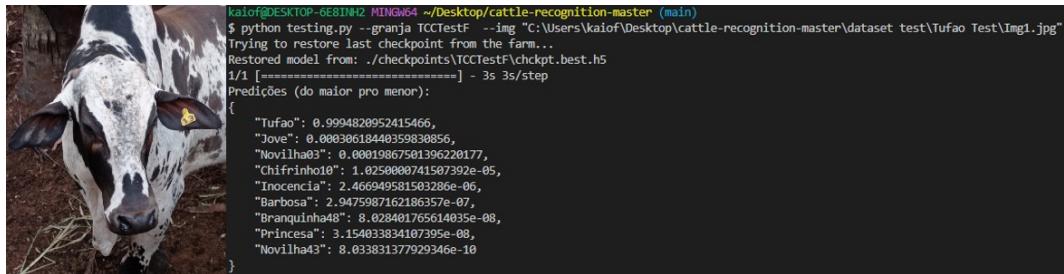
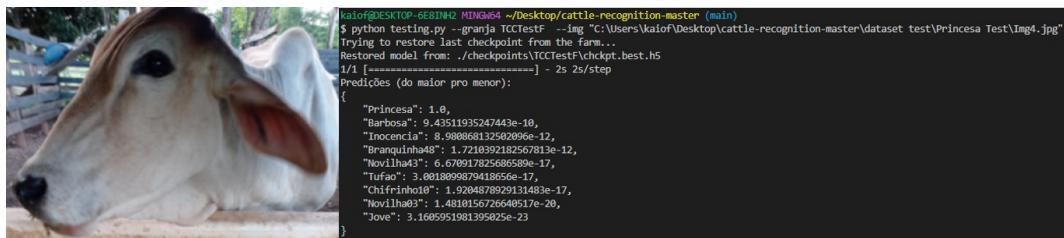


Figura 6 – Teste 4 - Princesa



Um caso curioso ocorreu com o Chifrinho10 que apesar de ser o animal com maior número de imagens de treino, o reconhecimento falhou em duas das três imagens de teste, mostradas nas Figuras 8 e 9. Esse erro ocorreu devido a um erro na gravação das imagens deste animal, em que um grande número delas o animal não está localizado no centro da gravação.

Figura 7 – Teste 2 - Inocência

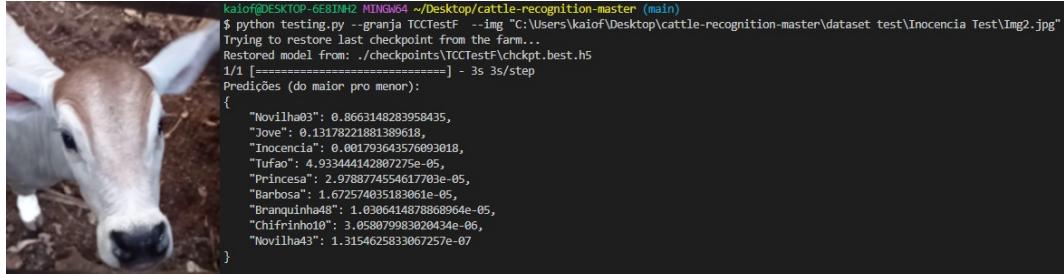


Figura 8 – Teste 1 - Chifrinho10

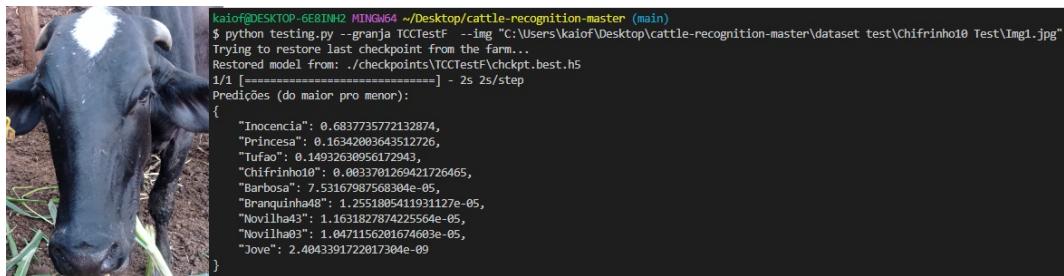
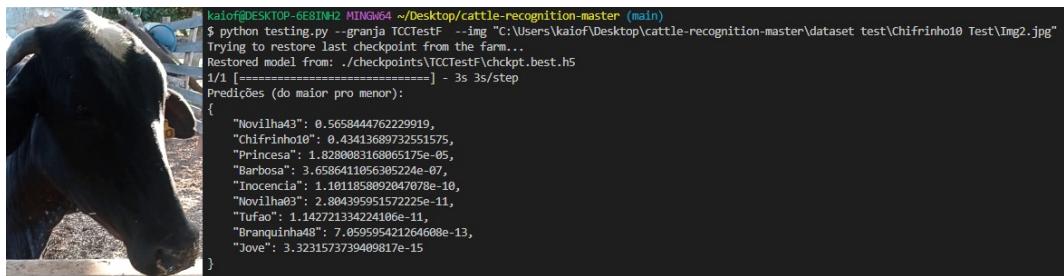


Figura 9 – Teste 2 - Chifrinho10



Dois animais foram selecionados por serem parecidos uns com os outros. O Jove possui um padrão de manchas na pelagem muito semelhante ao seu pai Tufão e a Novilha03 tem o pelo parecido com a Branquinha, como mostrado na Figura 10. Na Figura 11 vemos que a semelhança entre pai e filho confundiu o algoritmo que identificou a imagem de teste como Tufão. Durante o Teste 2 da Novilha03 o algoritmo mesmo acertando se confundiu na predição, ficando quase meio a meio entre as duas (Figura 12).

Figura 10 – Jove, Tufão, Novilha03 e Branquinha



Figura 11 – Teste 1 - Jove

```

kaiof@DESKTOP-6EBINH2 MINGW4 ~/Desktop/cattle-recognition-master (main)
$ python testing.py --granja TCCtestF --img "C:\Users\Kaiof\Desktop\cattle-recognition-master\dataset\test\Jove Test\Img1.jpg"
Trying to restore last checkpoint from the farm...
Restored model from: ./checkpoints\TCCtestF\chkpt.best.h5
1/1 [=====] - 2s 2s/step
Predições (do maior pro menor):
{
    "Tufão": 0.6930291652679443,
    "Jove": 0.30696871876716614,
    "Novilha03": 2.0035972338941973e-06,
    "Chifrinhola0": 1.1360056677922118e-07,
    "Barbosa": 2.675087415575692e-08,
    "Inocencia": 1.7159267340360884e-09,
    "Branquinha48": 3.746961629857992e-10,
    "Princesa": 3.465728051765815e-11,
    "Novilha43": 1.1357302901957023e-12
}
    
```

Figura 12 – Teste 2 - Novilha03

```

kaiof@DESKTOP-6EBINH2 MINGW4 ~/Desktop/cattle-recognition-master (main)
$ python testing.py --granja TCCtestF --img "C:\Users\Kaiof\Desktop\cattle-recognition-master\dataset\test\Novilha03 Test\Img2.jpg"
Trying to restore last checkpoint from the farm...
Restored model from: ./checkpoints\TCCtestF\chkpt.best.h5
1/1 [=====] - 3s 3s/step
Predições (do maior pro menor):
{
    "Novilha03": 0.5796074271202087,
    "Branquinha48": 0.4203904867172241,
    "Inocencia": 2.0549391592794564e-06,
    "Barbosa": 1.3278760313539866e-08,
    "Tufão": 2.4665161024728377e-09,
    "Chifrinhola0": 1.071910116223762e-09,
    "Princesa": 1.4992562746840576e-10,
    "Jove": 8.178610566567102e-12,
    "Novilha43": 5.98481088151965614e-15
}
    
```

## **4 CONCLUSÃO**

Durante o desenvolvimento do trabalho as maiores adversidades encontradas foram com relação ao comportamento dos animais e como isso afetou na quantidade e qualidade dos dados. Diversos autores apontam que esse é um dos principais obstáculos dessa tecnologia, principalmente os que a usam em ambientes selvagens. O *background* e iluminação foram outros fatores que também causaram empecilhos e falhas, como o caso já mostrado do Chifrinho<sup>10</sup>, porém são problemas contornáveis tomando cuidados na captura e tratando os dados.

A tecnologia de reconhecimento facial, apesar dos contratempos e dificuldades, foi funcional. Porém, para seu uso em uma fazenda real, seriam necessários investimentos que a tornam inviável para pequenos produtores. Para seu funcionamento é preciso de câmeras bem posicionadas em locais estratégicos, tempo e capacitação para coleta de dados e treinamento, constante manutenção do equipamento e a capacidade de integrar essa tecnologia com outras e transformar em um sistema automatizado.

Esse método de identificação poderia ser usado em conjunto com outras tecnologias. Pode-se integrar o reconhecimento facial com os alimentadores e balanças que captam dados dos animais enquanto os alimenta e assim usar o reconhecimento do rosto para armazenar os dados de forma totalmente automática. Outra situação de uso da tecnologia é durante as vacinações. Posicionando a câmera no brete onde são aplicadas as vacinas para que os produtores e veterinários não precisem anotar quais animais já foram vacinados, o sistema faria isso de forma automática. Nesses sistemas ideais os dados de teste devem ser captados e analisados em forma de vídeo e o algoritmo deve, se possível, analisar em tempo real o rosto do animal.

Essa tecnologia inovadora e cheia de vantagens tem potencial para substituir métodos de identificação invasivos. Porém, são necessários novos estudos para criar formas de tratar os dados e desenvolver novos algoritmos e técnicas visando melhorar a precisão do reconhecimento. A primeiro momento a prioridade deve ser nos dados e em processo de captura. Criar um plano visando minimizar as influências externas evita que elas afetem o resultado do reconhecimento. As fazendas que querem utilizar essa tecnologia precisam investir nesse método de identificação que fornece uma nova forma gerenciar os animais sem prejudicá-los.

## REFERÊNCIAS

- [1] ORVALHO, V. Reconhecimento facial. *Revista de Ciência Elementar*, v. 7, p. 073, 2019. Disponível em: <<https://rce.casadasciencias.org/rceapp/art/2019/073/>>.
- [2] HARALICK, R. M. Performance characterization in computer vision. In: HOGG, D.; BOYLE, R. (Ed.). *BMVC92*. London: Springer London, 1992. p. 1–8. ISBN 978-1-4471-3201-1.
- [3] SCHMIDT, E. C. N. A. E. Estudo sobre métodos de reconhecimento facial em fotografias digitais. *IFC-Camboriú*, 2017. Disponível em: <<https://docplayer.com.br/48875015-O-reconhecimento-facial-e-dividido-em-tres-etapas-i-deteccao-da-face-ii-extracao-de-caracteristicas-e-iii-reconhecimento-da-face.html>>.
- [4] DATA augmentation. *TensorFlow Core*, 2022. Disponível em: <[https://www.tensorflow.org/tutorials/images/data\\_augmentation?hl=en](https://www.tensorflow.org/tutorials/images/data_augmentation?hl=en)>.
- [5] DAMASCENO, G. S. de S. Reconhecimento facial com variações de iluminação utilizando pca e modificações da dct associadas aos classificadores gmm, naive bayes e k-nn. *Programa de pós-graduação em ciência da computação da Universidade Estadual do Ceará*, 2017. Disponível em: <<https://www.uece.br/wp-content/uploads/sites/51/2020/02/GISELLY-SOARES.pdf>>.
- [6] BILLAH, M. et al. Real-time goat face recognition using convolutional neural network. *Computers and Electronics in Agriculture*, v. 194, p. 106730, 2022. ISSN 0168-1699. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0168169922000473>>.
- [7] HANSEN, M. F. et al. Towards on-farm pig face recognition using convolutional neural networks. *Computers in Industry*, v. 98, p. 145–152, 2018. ISSN 0166-3615.
- [8] CLAPHAM, M. et al. Automated facial recognition for wildlife that lack unique markings: A deep learning approach for brown bears. *Ecology and evolution*, John Wiley Sons Ltd., v. 10, p. 12883–12892, Dec 2020. Disponível em: <<https://doi.org/10.1002/ece3.6840>>.
- [9] BELLO, R.-W. et al. Image-based individual cow recognition using body patterns. *International Journal of Advanced Computer Science and Applications*, The Science and Information Organization, v. 11, n. 3, 2020. Disponível em: <<http://dx.doi.org/10.14569/IJACSA.2020.0110311>>.
- [10] XUE, H. et al. Open set sheep face recognition based on euclidean space metric. *Mathematical Problems in Engineering*, Hindawi, v. 2021, p. 3375394, Nov 2021. ISSN 1024-123X. Disponível em: <<https://doi.org/10.1155/2021/3375394>>.
- [11] KUMAR, S.; SINGH, S. Face recognition of cattle. In: . [S.l.: s.n.], 2015.
- [12] WANG, K.; CHEN, C.; HE, Y. Research on pig face recognition model based on keras convolutional neural network. *IOP Conference Series: Earth and Environmental Science*, IOP Publishing, v. 474, n. 3, p. 032030, apr 2020. Disponível em: <<https://doi.org/10.1088/1755-1315/474/3/032030>>.

- [13] MATKOWSKI, W. M. et al. Giant panda face recognition using small dataset. In: *2019 IEEE International Conference on Image Processing (ICIP)*. [S.l.: s.n.], 2019. p. 1680–1684.
- [14] ACADEMY, D. S. Capítulo 40 – introdução as redes neurais convolucionais. In: \_\_\_\_\_. *Deep Learning Book*. DSA. Disponível em: <[https://www.deeplearningbook.com.br/introducao-as-redes-neurais-convolucionais/#:~:text=Uma%20Rede%20Neural%20Convolucional%20\(ConvNet,de%20diferenciar%20um%20do%20outro.\)](https://www.deeplearningbook.com.br/introducao-as-redes-neurais-convolucionais/#:~:text=Uma%20Rede%20Neural%20Convolucional%20(ConvNet,de%20diferenciar%20um%20do%20outro.))>
- [15] MARSOT, M. et al. An adaptive pig face recognition approach using convolutional neural networks. *Computers and Electronics in Agriculture*, v. 173, p. 105386, 2020. ISSN 0168-1699. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0168169920300673>>.
- [16] BELLO, R.-w.; TALIB, A. Z. H.; MOHAMED, A. S. A. B. Deep learning-based architectures for recognition of cow using cow nose image pattern. *Gazi University Journal of Science*, Gazi University, v. 33, n. 3, p. 831 – 844, 2020.
- [17] BLANCO, E. Identificación de ganado con convolutional neural networks (cnns). *Repositório Github*, out 2019. Disponível em: <<https://github.com/eblancoh/cattle-recognition>>.
- [18] CÁRDENAS-MONTES, M. Sobreajuste - overfitting. *Ciemat - Centro de Investigaciones Energéticas Medioambientales y Tecnológicas*. Disponível em: <<http://wwwae.ciemat.es/~cardenas/docs/lessons/sobreajuste.pdf>>.

## **Apêndices**

## APÊNDICE A – CÓDIGO

Quadro 3 – Programa *frames.py*



```
12 lines (12 sloc) | 516 Bytes
1 import cv2
2 def FrameCapture(path):
3     vidObj = cv2.VideoCapture(path)
4     count = 1 #Começa no numero do frame que deseja
5     success = 1
6     while success:
7         success, image = vidObj.read()
8         image = cv2.flip(image, 0) #Deixar comentado se o video estiver na horizontal
9         cv2.imwrite("frame%d.jpg" % count, image)
10        count += 1
11 if __name__ == '__main__':
12     FrameCapture("C:\\\\Users\\\\kaiofbgarcia\\\\Desktop\\\\Imagens de Teste\\\\Branquinha48 Test\\\\I1.mp4") #Colocar caminho para o video desejado
```

Fonte: <https://github.com/kaiofbgarcia/Reconhecimento-Facial-Bovino/blob/main/frames/frames.py>

Quadro 4 – README do Repositório



**Reconhecimento Facial de Gado Bovino - TCC**

O seguinte repositorio foi modificado tendo base o Cattle Recognition (<https://github.com/eblancoh/cattle-recognition>), e segue seu princípio de código aberto.

**Dataset**

As imagens devem ser colocadas em pastas com os nomes dos animais dentro de uma pasta nomeada "dataset".

**Treinamento**

Para realizar o treinamento deve-se utilizar o comando abaixo, substituindo "test" pelo nome desejado para o treinamento.

```
$ python training.py --granja test --model resnets0 --epochs 20 --batch_size 30
```

**Gerar Gráficos do Treinamento**

Para analisar o treinamento é possível visualizar gráficos de accuracy e loss com o TensorBoard.

```
$ cd logs/folder/
$ tensorboard --logdir= ./ --port 6006
```

**Testes**

Para realizar um teste individual se utiliza o comando abaixo, passando o nome do treinamento e o path da imagem de teste.

```
$ python testing.py --granja test --img "path/to/img"
```

Fonte: <https://github.com/kaiofbgarcia/Reconhecimento-Facial-Bovino#readme>